Задача 5: Лінійна регресія в Python

Використано `train.csv`: 1460 спостережень. Для багатофакторної регресії — 1201 повний рядок. Повна модель містить шість числових регресорів із завдання та `C(MSSubClass)`. Структурні категорії `NA` збережено; рівень значущості — 0.05.

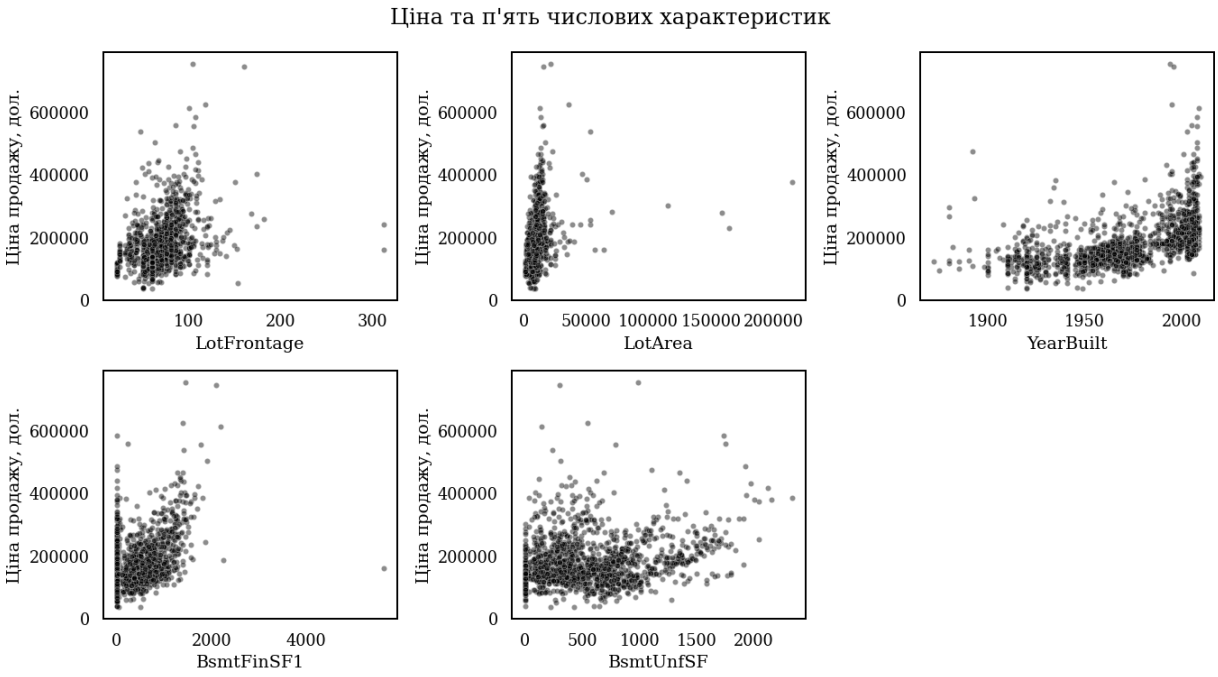
(1) Обговоріть Label Encoding та dummy-кодування `MSSubClass`. Порівняйте регресії з числовою та категоріальною змінною.

`MSSubClass` — номінальна ознака: числові коди не задають порядку чи відстані. Тому використано 14 індикаторів для 15 наявних типів; база — тип 20. Для порядкової шкали існує порядок, для кардинальної — змістовні числові різниці.

Варіант	Параметрів	R^2
MSSubClass як int64	2	0.007104
C(MSSubClass)	15	0.246316
pd.Categorical	15	0.246316

Числовий варіант оцінює одну пряму. `C(...)` та `pd.Categorical` дають однакові прогнози.

(2) Побудуйте діаграми залежності `SalePrice` від `LotFrontage`, `LotArea`, `YearBuilt`, `BsmtFinSF1`, `BsmtUnfSF`. Запропонуйте перетворення.



`LotFrontage`: додатний зв’язок, великі значення й пропуски; можливий логарифм. `LotArea`: сильна асиметрія; доцільні логарифм і перевірка впливових ділянок. `YearBuilt`: новіші будинки дорожчі; можливі вік, квадрат віку чи сплайн. `BsmtFinSF1`: багато нулів і крайній підвал; можливі `log1p` та індикатор ненульової площі. `BsmtUnfSF`: слабший зв’язок; можна врахувати частку завершеного підвалу.

(3) Оцініть OLS без перетворень. Перевірте значущість `LotArea`, поясніть R^2 та скоригований R^2.

Проста модель: $\widehat{P} = 158836.151897 + 2.099972\,LotArea$.

$$H_0: \beta_1 = 0, \quad H_1: \beta_1 \neq 0, \qquad t = \frac{\widehat{\beta}_1}{SE(\widehat{\beta}_1)} = \frac{2.099972}{0.201058} = 10.444633.$$

Ступені свободи: 1458; $p = 1.12314 \cdot 10^{-24}$. Нульову гіпотезу відхилено. $R^2 = 0.069613$, $\bar{R}^2 = 0.068975$: сама площа пояснює близько 7% варіації цін.

$$R^2 = 1 - \frac{SSE}{SST}, \qquad \bar{R}^2 = 1 - \frac{SSE/(n-k)}{SST/(n-1)}.$$

k включає константу. Звичайний R^2 не зменшується при додаванні змінних; скоригований штрафує зайві параметри. Для повної моделі: $R^2 = 0.618080$, $\bar{R}^2 = 0.611607$, $k = 21$.

(4) Перевірте спільну значущість індикаторів `MSSubClass` методом `f_test()`; запишіть матрицю обмежень.

$$H_0: \gamma_1 = \cdots = \gamma_{14} = 0, \qquad R = [0_{14\times 1}\; I_{14}\; 0_{14\times 6}], \quad r = 0_{14\times 1}.$$

Порядок параметрів: константа, 14 індикаторів, 6 числових коефіцієнтів. $F(14, 1180) = 18.137812$, $p = 2.24963 \cdot 10^{-41}$. Фактор спільно значущий. Робастна перевірка HC3: $p = 2.30510 \cdot 10^{-42}$.

(5) Інтерпретуйте `LotArea`, перший dummy та `BedroomAbvGr` у моделях ціни й логарифма ціни.

Параметр	Модель ціни	Модель log(ціни)
LotArea	1.239472	0.000005190
Тип 30 щодо типу 20	13 561.490340	-0.062684
BedroomAbvGr	5 338.201570	0.051582

За інших рівних умов додатковий кв. фут ділянки змінює очікувану ціну на 1.239472 дол., додаткова спальня — на 5 338.20 дол. Dummy порівнює тип 30 із базою 20, а не збільшення коду на одиницю; окремого коефіцієнта типу 20 немає. Це умовні асоціації. Порівняння типів 30 і 20 за однакового року побудови потребує екстраполяції.

Для лог-моделі зміна геометричного середнього — $100(e^{\beta\Delta x} - 1)\%$: 1000 кв. футів дають 0.5203%, спальня — 5.2935%, тип 30 щодо 20 — -6.0760%.

(6) Обчисліть 95% інтервал для `LotArea` та перевірте нормальність залишків.

Інтервал	Нижня межа	Верхня межа
Класичний	0.819819	1.659125
HC3	-0.448993	2.927938

Межі — долари за кв. фут. Класичний інтервал не містить нуля, HC3 містить: висновок про значущість чутливий до оцінки похибок. Шапіро—Вілк: $p = 2.82695 \cdot 10^{-36}$; Jarque—Bera: $p < 10^{-300}$. Нормальність відхилено. Бройш—Паган: $p = 1.55041 \cdot 10^{-74}$ — дисперсія нестала. Без класичних припущень точні t/F-висновки не гарантовані.

(7) Виберіть економну модель власним покроковим алгоритмом за AIC/BIC та використовуйте її далі.

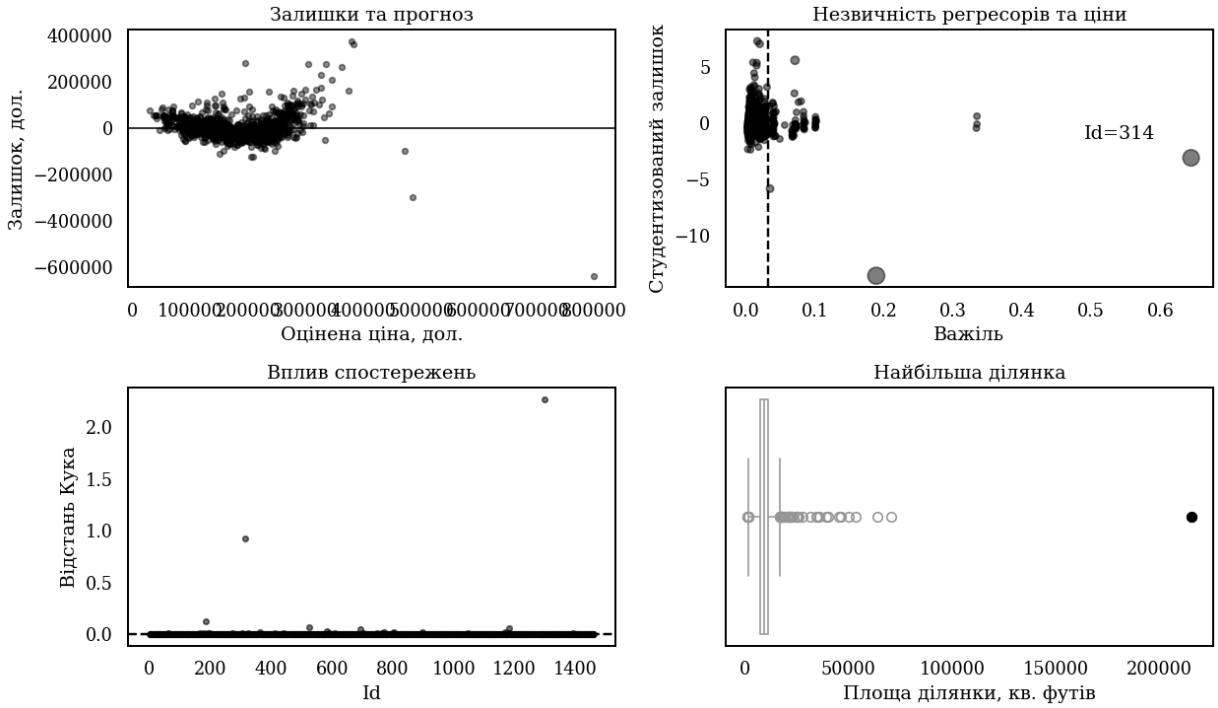
Використано backward BIC: починаючи з повної моделі, на кожному кроці вилучаю групу, яка найбільше зменшує $BIC = n\log(SSE/n) + k\log n + const$. Зупиняюся, коли поліпшення немає. Індикатори `MSSubClass` перевіряю однією групою.

Модель	Параметрів	R^2	BIC
Повна	21	0.618080	29 617.913031
Без LotFrontage	20	0.616940	29 614.400410
Без LotFrontage і BedroomAbvGr	19	0.615078	29 613.135520

Залишено `LotArea`, `YearBuilt`, `BsmtFinSF1`, `BsmtUnfSF`, `C(MSSubClass)`. Втрата пояснювальної здатності невелика. Пошук жадібний, тому глобальний мінімум BIC не гарантований.

(8) Перевірте викиди, відстань Кука та leverage через `OLSInfluence`. Поясніть найбільший важіль.

$$h_i = x_i^{'}(X^{'}X)^{-1}x_i, \qquad D_i = \frac{\widehat{u_i}^2}{k\widehat{\sigma}^2}\frac{h_i}{(1-h_i)^2}.$$



Найбільший важіль: Id=314, $h = 0.644460$, $D = 0.926359$. Площа ділянки — 215 245 кв. футів проти медіани 9 262; тип 20 поширений (437 будинків). Причина — крайня площа, а не рідкісна категорія.

Найбільша відстань Кука — у Id=1299 ($D = 2.2649$). Пороги $2k/n$ і $4/n$ перевищують відповідно 88 та 49 рядків. Без Id=314 коефіцієнт `LotArea` змінюється з 1.359764 до 2.223689. Спостереження залишено: незвичне значення саме по собі не доводить помилку в даних.

(9) Видаліть п’ять випадкових значень `LotArea` та застосуйте два способи імпутації на повному наборі характеристик.

Використано 1460 рядків, 79 характеристик без `Id` і ціни, seed=42. Методи: медіана та `IterativeImputer` з регресіями Bayesian Ridge $x_j = a_j + X_{-j}b_j + \varepsilon_j$ і послідовним оновленням пропусків.

Id	Справжня площа	Медіана	Ітеративна
1128	14 572	9 477.00	38 400.75
641	12 677	9 477.00	5 804.81
955	9 400	9 477.00	1.00
130	8 973	9 477.00	7 296.40
633	11 900	9 477.00	11 325.16

RMSE: медіана — 2 909.6357, ітеративна — 11 887.1290 кв. футів. На цих п’яти рядках медіана краща. Структурні `NA` збережено, відомі значення не змінено.

(10) Порівняйте моделі `SalePrice` і `log(SalePrice)` відповідним тестом. Поясніть обмеження прямого зіставлення AIC/BIC.

Тест Бокса—Кокса: $g_\lambda(y) = (y^\lambda - 1)/\lambda$, а $g_0(y) = \log y$. Оцінено $\widehat{\lambda} = -0.018913$.

Нульова гіпотеза	LR	p
λ=0 (логарифм)	0.255844	0.612990
λ=1 (рівні)	668.536437	2.07916×10^{-147}

$LR = 2[\ell(\widehat{\lambda}) - \ell(\lambda_0)] \sim \chi^2_1$ асимптотично. Логарифм не відхилено, рівні відхилено. AIC/BIC різних шкал потребують поправки на якобіан: для log-моделі до AIC додається $2\sum \log y_i$.

(11) Порівняйте повну та скорочену моделі за LeaveOneOut і KFold (5 блоків), використовуючи MSE.

$$MSE_{CV} = \frac{1}{n}\sum_i [y_i - \widehat{f}_{-fold(i)}(x_i)]^2.$$

У LOO навчання без одного рядка, у KFold — без одного з п’яти блоків. Відбір BIC повторюється на навчальних рядках. Для log-моделі прогноз у доларах: $\widehat{P} = e^{x\widehat{\beta}}\,\mathrm{mean}_{train}(e^{\widehat{u}})$.

Перевірка	Модель	MSE, дол.²	RMSE, дол.
LOOCV	Повна, рівні	3 039 111 059.60	55 128.13
LOOCV	BIC, рівні	3 082 499 633.52	55 520.26
LOOCV	Повна, log	37 545 736 165.21	193 767.22
LOOCV	BIC, log	43 962 043 199.35	209 671.27
KFold-5	Повна, рівні	3 251 553 737.12	57 022.40
KFold-5	BIC, рівні	3 276 900 084.25	57 244.21
KFold-5	Повна, log	56 027 036 419.23	236 700.31
KFold-5	BIC, log	63 717 467 710.28	252 423.19

Найнижча MSE — у повної моделі в рівнях; скорочена в рівнях близька за якістю. Лог-модель нестійка: для Id=1299 LOO-прогноз 7 182 929.39 дол. за ціни 160 000 дол. Цей рядок дає 93.41% суми квадратів її помилок. Краща підгонка після логарифмування не гарантує кращого доларового прогнозу.

Задача 6: Нелінійні регресії в Python

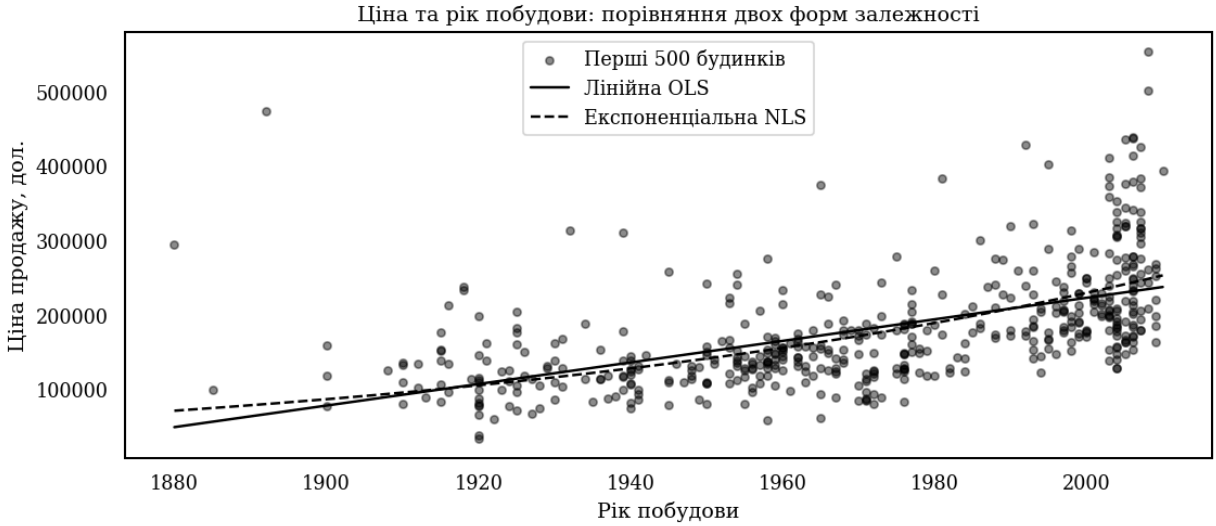
Використано перші 500 рядків початкового `train.csv`.

(а) Побудуйте діаграму `SalePrice` від `YearBuilt`, оцініть лінійну модель та додайте пряму.

$$\widehat{P} = 79355.140754 + 1447.763883(YearBuilt - 1900).$$

(б) Оцініть нелінійну модель через `curve_fit`, додайте криву та порівняйте R^2 і MSE.

$$\widehat{P} = 87868.176740 \exp\left[0.965714 \frac{YearBuilt - 1900}{100}\right].$$



Модель	R^2	MSE, дол.²
Лінійна	0.303048	4 297 426 767.37
Експоненціальна NLS	0.343553	4 047 673 152.34

Нелінійна модель зменшила навчальну MSE на 5.8117%. Три початкові точки дали практично однаковий мінімум. Це перевага підгонки, а не перевірка на нових даних.

(в) Поясніть, чому точні класичні тести не застосовуються до NLS автоматично.

Оцінки NLS нелінійно залежать від спостережень, тому точний маловибірковий t-розподіл не гарантований. `curve_fit` дає локальне наближення коваріації $\widehat{\sigma}^2 (J'J)^{-1}$. Для висновків потрібні асимптотичні методи або bootstrap та перевірка моделі похибок.

(г) Які проблеми збіжності та перенавчання виникають при використанні всіх регресорів?

Можливі локальні мінімуми, залежність від старту, нестійкий Якобіан і колінеарність. Багато параметрів на 500 рядках збільшують ризик перенавчання. Допомагають масштабування, межі параметрів, кілька стартів, регуляризація та крос-валідація.

Код обчислень і повні результати: `lab3_regression.ipynb`.