Задача 7: Методи регресійного аналізу в Python

Дані: Ames Housing, 1460 будинків, 79 характеристик без Id. Регресія: 1168 навчальних і 292 валідаційних рядки. Seed=42; структурні категорії NA збережено.

(1а) Поясніть Lasso, його застосування за колінеарності та спосіб оцінювання.

$$\min_{\beta_0,\beta} \frac{1}{2n} \sum_i (y_i - \beta_0 - x_i'\beta)^2 + \alpha \sum_j |\beta_j|.$$

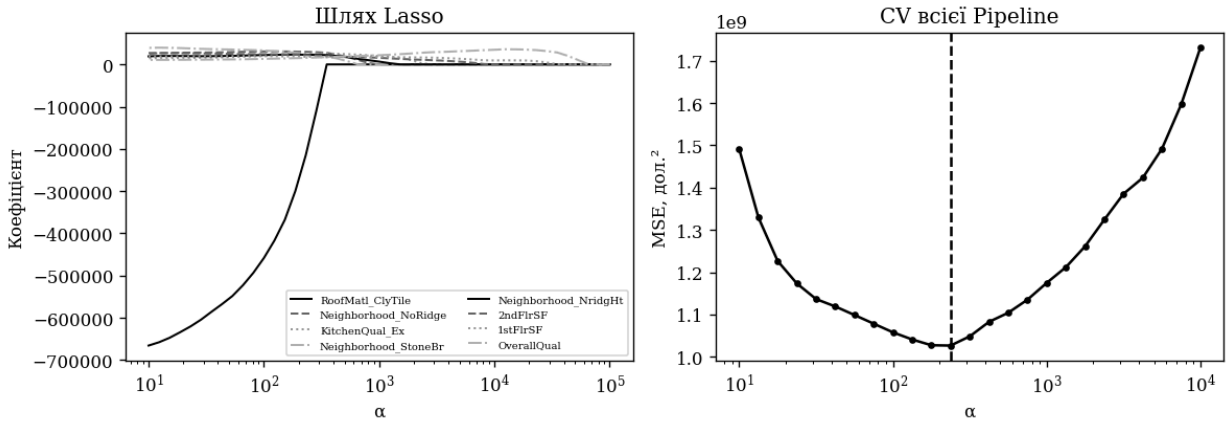
Штраф L1 стискає коефіцієнти й зануляє частину з них. За p>n чи колінеарності OLS не має єдиного розв'язку; Lasso можна оцінити, хоча єдиність також не завжди гарантована. Модуль недиференційовний у нулі, тому використовується числовий координатний спуск. Ridge для центрованих даних має розв'язок $(X'X + \alpha I)^{-1}X'y$.

(1б) Масштабуйте числові дані, поясніть обробку dummy та FireplaceQu.

StandardScaler навчається всередині CV: $z_j = (x_j - \bar{x}_j)/s_j$. Це прибирає залежність штрафу від одиниць вимірювання. Dummy залишено 0/1; стандартизація можлива, але змінює штраф для рідкісних рівнів. FireplaceQu та інші категорії обробляє OneHotEncoder, включно з NA.

Після кодування — 310 колонок. QR залишив 256 лінійно незалежних, щоб коефіцієнти OLS були визначені. Перетворення не використовують контрольних рядків CV.

(1в) Побудуйте шлях Lasso та виберіть α п'ятикратною крос-валідацією.



LassoCV: α=177.827941. Остаточна CV всієї Pipeline: **α=237.137371**, ненульових коефіцієнтів — 71. Рекомендую друге значення: його перевірка враховує навчання імпутації, масштабування й QR у кожному блоці. На графіку показано вісім найбільших за модулем ненульових коефіцієнтів.

(1г) Оцініть Ridge з оптимальним α та порівняйте коефіцієнти й дисперсії з OLS.

Ridge: **α=61.896582** за 5-блочною CV. OLS оцінено на тій самій масштабованій матриці. Для центрованих регресорів і сталої дисперсії похибок:

$$Cov(\widehat{\beta}_{OLS}) = \widehat{\sigma}^2 (X'X)^{-1}, \quad Cov(\widehat{\beta}_{Ridge}) = \widehat{\sigma}^2 A^{-1} X'X A^{-1}, \quad A = X'X + \alpha I.$$

Десять найбільших коефіцієнтів OLS за модулем:

Ознака	β OLS	β Ridge	Var OLS	Var Ridge
PoolQC_Gd	-5 148 578.23	-5 353.74	5.0921e+11	9.5821e+04
PoolQC_Fa	-4 557 161.12	-251.03	3.9371e+11	1.0473e+05
PoolQC_Ex	-3 675 428.65	4 421.71	2.7155e+11	1.1967e+05
RoofMatl_ClyTile	1 021 908.57	-6 258.55	6.4684e+10	5.3921e+04
MiscFeature_Shed	-852 463.45	-103.76	1.6875e+10	7.1493e+05
MiscFeature_NA	-849 754.60	328.51	1.6971e+10	6.5940e+05
MiscFeature_Othr	-827 409.69	184.54	1.9293e+10	9.4541e+04
PoolArea	294 524.23	244.30	1.6190e+09	3.8458e+05
GarageQual_Ex	174 081.85	2 087.60	1.6119e+09	2.4534e+05
GarageCond_TA	150 782.37	1 222.39	1.1801e+09	9.9338e+05

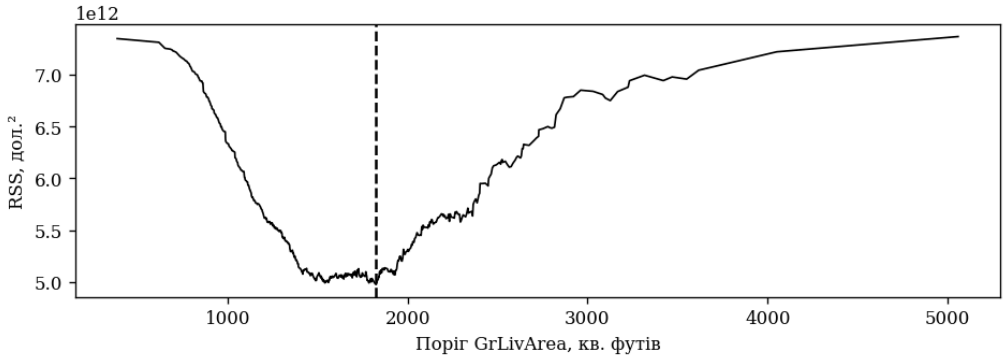
Медіана Var(Ridge)/Var(OLS)=0.002684. Ridge додає зміщення, але зменшує дисперсію. OLS особливо нестійка для рідкісних категорій. Якість на 292 валідаційних будинках:

Модель	MSE, дол.²	RMSE, дол.	R²
OLS	12 430 912 099.21	111 494.00	-0.973907
Lasso	1 168 454 709.90	34 182.67	0.814461
Ridge	1 236 474 756.66	35 163.54	0.803660

(2а–б) Запишіть та вручну розв’яжіть задачу першого розщеплення за GrLivArea.

$$\min_s \left[\sum_{x_i \le s} (y_i - \bar{y}_L)^2 + \sum_{x_i > s} (y_i - \bar{y}_R)^2 \right].$$

Перевірено середини між сусідніми різними площами. Жадібний пошук обирає найкращий поточний розріз. Ручний поріг і DecisionTreeRegressor(max_depth=1) збігаються: **s=1 825.0**, RSS=4 977 562 477 455.61, вузли 897 і 271 будинків.



(2в) Поясніть розщеплення OverallQual і роботу з категоріями.

Для порядкової якості 1–10 перевіряються пороги 1.5, 2.5, …, 9.5; найкращий — **7.5**. Для номінальних категорій використано індикатори, щоб не створювати штучного порядку.

(2г–д) Обмежте CART десятьма розщепленнями та дослідіть ccp_alpha.

max_leaf_nodes=11: отримано 11 листів, 10 розщеплень, глибину 5. Стрижка мінімізує $R(T) + \alpha|\text{листи}|$. Шлях cost_complexity_pruning_path:

ccp_alpha	Листів	Глибина	MSE валідації
0.00	11	5	1 832 011 599.81
74 125 606.17	10	4	1 784 455 264.88
90 683 502.61	9	4	1 886 270 418.44
90 996 792.03	8	3	1 848 711 286.61
95 274 123.27	7	3	2 053 889 661.84
133 426 142.42	6	3	2 109 701 396.18
155 707 518.67	5	3	2 580 748 759.09
235 555 833.04	4	2	2 851 141 888.45
389 586 086.19	3	2	3 294 680 808.97
754 358 957.29	2	1	3 941 569 415.15
2 985 354 420.22	1	0	6 303 529 160.85

За α=0 дерево зберігає 11 листів; збільшення α послідовно скорочує його до кореня.

(2е) Обчисліть зменшення неоднорідності в корені.

Кореневе правило: **OverallQual ≤ 7.5**.

$$\begin{aligned}\Delta I &= I_0 - \frac{n_L}{n_0} I_L - \frac{n_R}{n_0} I_R \\ &= 6307898975.94 - \frac{991}{1168} 2428149108.42 - \frac{177}{1168} 8330148444.29 \\ &= 2985354420.22.\end{aligned}$$

У squared_error це зменшення середньої квадратичної неоднорідності; зменшення RSS — $n_0 \Delta I$.

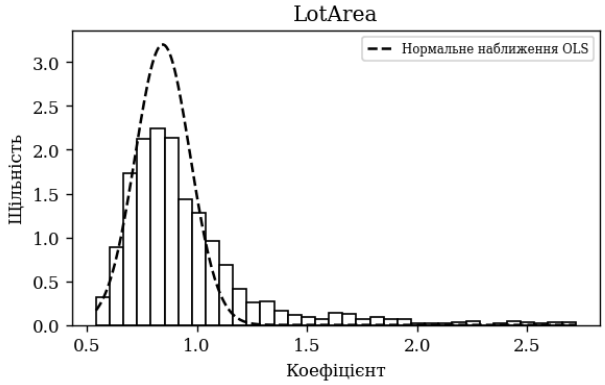
(2ж) Порівняйте топ-10 важливостей дерева з коефіцієнтами Lasso та OLS.

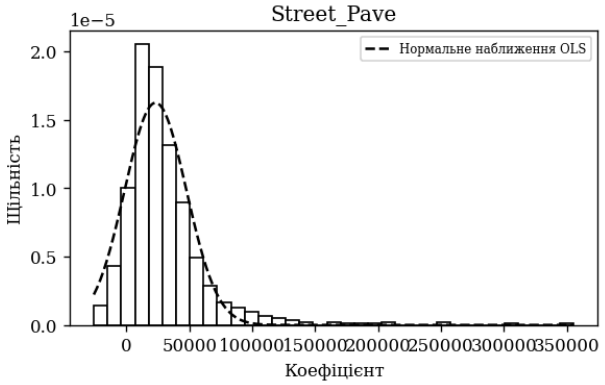
Ознака	MDI дерева	β Lasso	β OLS
OverallQual	0.825023	15 545.27	10 265.12
GrLivArea	0.107567	—	—
2ndFlrSF	0.031110	22 038.74	26 019.75
GarageCars	0.018181	9 424.88	3 382.26
TotalBsmtSF	0.018118	7 505.82	18 523.89
LotFrontage	0.000000	-868.08	145.99
LotArea	0.000000	3 747.58	10 098.98
OverallCond	0.000000	6 057.78	6 445.57
YearBuilt	0.000000	8 117.83	9 772.36
YearRemodAdd	0.000000	1 118.93	2 323.48

MDI — нормована сума зменшень неоднорідності. Числові β задано за одну стандартну девіацію, dummy — за зміну 0→1. Риска означає QR-вилучену залежну колонку. У дерева лише п’ять ненульових важливостей, тому решта позицій топ-10 — нулі.

(2з–и) Виконайте 1000 бутстреп-повторів для LotArea і Street та порівняйте 95% інтервали.

Беру перші 10 числових ознак і додаю Street_Pave, бо Street є категоріальною. У кожному повторі — df.sample(replace=True), потім LinearRegression. Гістограми порівняно з нормальним наближенням OLS із дисперсією з $\widehat{\sigma}^2(X'X)^{-1}$.

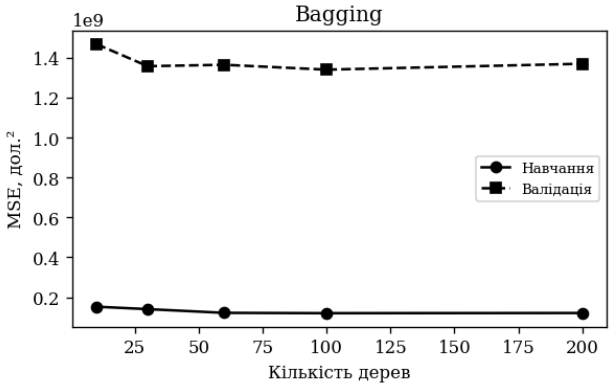


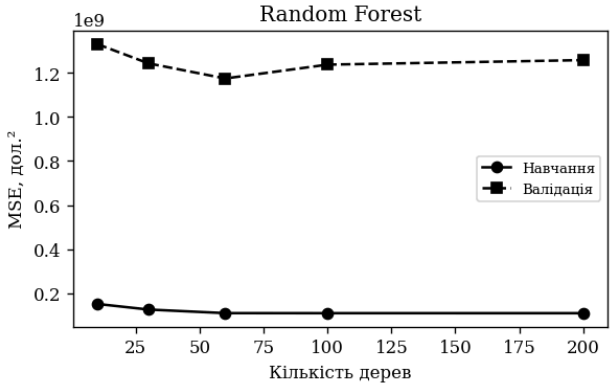


Параметр	β OLS	Boot 2.5%	Boot 97.5%	OLS low	OLS high
LotArea	0.8446	0.6182	1.8892	0.6001	1.0890
Street_Pave	23 099.2480	-11 727.0099	113 265.3746	-25 110.5363	71 309.0324

Для LotArea оцінено 1000 повторів; для Street — 950. В інших повторах не було обох рівнів Street, тому її коефіцієнт не ідентифікований. Медіани імпутації фіксовані. Ширший і несиметричний бутстреп-інтервал показує нестійкість оцінки Street.

(2і) Застосуйте Bagging і Random Forest та побудуйте криві MSE за кількістю дерев.





Навчальна помилка нижча; валідаційна загалом стабілізується, але не зменшується монотонно. На сітці найкращі: Bagging — **100** дерев, MSE=1 339 916 771.67; Random Forest — **60**, MSE=1 174 515 992.92.

(2к) Порівняйте час ансамблів та поясніть різницю.

Дерев	MSE Bagging	MSE Forest	Bagging, с	Forest, с
10	1.46760e+09	1.33028e+09	0.1454	0.0572
30	1.35727e+09	1.24303e+09	0.4337	0.1694
60	1.36431e+09	1.17452e+09	0.8537	0.3340
100	1.33992e+09	1.23729e+09	1.4172	0.5552
200	1.36944e+09	1.25785e+09	2.8671	1.1091

Час накопичений для послідовного додавання дерев, n_jobs=1. У лісі перевіряється 1/3 ознак на вузол, у беггінгу — всі. Тут ліс швидший і досягає найкращого MSE з меншою кількістю дерев; загальної гарантії немає.

(2к), продовження. Підсумкова таблиця важливостей, топ-10 за Random Forest:

Ознака	Lasso	OLS	Дерево	Forest
OverallQual	0.071963	0.004202	0.825023	0.256404
GarageCars	0.043630	0.001385	0.018181	0.123564
GrLivArea	0.000000	0.000000	0.107567	0.098906
ExterQual	0.014037	0.005879	0.000000	0.068044
TotalBsmtSF	0.034747	0.007583	0.018118	0.064744
1stFlrSF	0.083623	0.007870	0.000000	0.045427
YearBuilt	0.037580	0.004001	0.000000	0.038490
BsmtQual	0.046891	0.007888	0.000000	0.034624
GarageArea	0.000000	0.001090	0.000000	0.032072
FullBath	0.014722	0.000830	0.000000	0.025126

Для лінійних моделей наведено частки $|\beta_j| sd(x_j)$, для дерев — MDI; індикатори підсумовано за початковою ознакою. Значення мають різний зміст. GrLivArea вилучено з лінійної бази як суму площ поверхів: нуль не означає відсутності інформації. MDI може надавати перевагу неперервним ознакам і не є причинним ефектом.

(3а) Оцініть Logit для Y=1[SalePrice>130000] зі зворотним відбором за AIC.

Навчання — 876 рядків; вибір порогу — 292; перевірка — 292. Початок — лише числові ознаки без точних залежностей. PoolArea вилучено через квазіповне розділення: чотири ненульові навчальні значення належать класу 1. На кожному кроці вилучено змінну, що найбільше зменшує AIC. Фінальна модель: **16 регресорів**, AIC=**364.999381**.

Ознака	β для стандартизованого x	p
const	4.255794	2.526e-28
LotFrontage	0.506890	3.235e-02
LotArea	1.765502	1.579e-03
OverallQual	1.080821	2.325e-04
OverallCond	0.926435	2.290e-06
YearBuilt	1.671682	6.166e-10
YearRemodAdd	0.272989	1.329e-01
BsmtFinSF1	0.589806	3.088e-02
TotalBsmtSF	0.782820	2.748e-03
1stFlrSF	1.591511	2.882e-06
2ndFlrSF	2.078526	3.666e-10
BsmtFullBath	0.337626	6.932e-02
BsmtHalfBath	0.537905	4.021e-03
HalfBath	0.361506	5.562e-02
KitchenAbvGr	-0.323941	2.603e-02
Fireplaces	0.335111	6.006e-02
GarageArea	0.356976	5.236e-02

(3б) Інтерпретуйте LotArea через Odds Ratio.

У початкових одиницях β=0.0001845415; $e^{\beta} = 1.00018456$ за 1 кв. фут, $e^{1000\beta} = 1.202667$ за 1000 кв. футів. Отже, додаткові 1000 кв. футів збільшують шанси дорогого будинку приблизно на 20.2667%, за інших рівних умов. Це не стала зміна ймовірності.

(3в) Назвіть значущі додатні й від'ємні коефіцієнти.

За $p<0.05$ додатні: LotFrontage, LotArea, OverallQual, OverallCond, YearBuilt, BsmtFinSF1, TotalBsmtSF, 1stFlrSF, 2ndFlrSF, BsmtHalfBath. Від'ємний: KitchenAbvGr. Площа, якість і новіший рік мають очікувані знаки; KitchenAbvGr — умовна асоціація, а не причинна шкода кухні. p-значення не враховують попереднього відбору.

(3г) Виберіть п’ять випадкових будинків, обчисліть імовірності й наведіть формулу для першого.

Id	SalePrice	Y	P(Y=1)	Клас при 0.5
1171	171 000	1	0.95863778	1
267	185 000	1	0.99833801	1
581	181 900	1	0.99923708	1
644	152 000	1	0.95127883	1
1201	116 050	0	0.03138791	0

Для Id=1171 у початкових одиницях, у порядку ознак із таблиці коефіцієнтів без const:

$$z = -153.433901897 + (0.024132029)\cdot 76 + (0.00018454149)\cdot 9880 + (0.78706797)\cdot 6 + (0.83140686)\cdot 6 + (0.05534407)\cdot 1977 + (0.01321257)\cdot 1977 + (0.0013454676)\cdot 522 + (0.0018594428)\cdot 1096 + (0.0041146769)\cdot 1118 + (0.0047830993)\cdot 0 + (0.64888403)\cdot 1 + (2.4627596)\cdot 0 + (0.72242682)\cdot 0 + (-1.4168811)\cdot 1 + (0.51379339)\cdot 1 + (0.0016372315)\cdot 358 \approx 3.143145516.$$

$$p = \frac{1}{1+e^{-z}} = \frac{1}{1+e^{-(3.143145516)}} = 0.958637785.$$

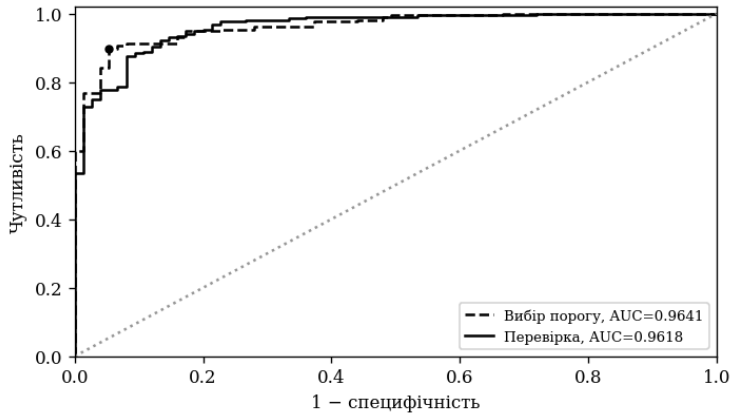
Клас — 1[p≥c], стандартно c=0.5.

(3д) Побудуйте матрицю помилок при 0.5 та поясніть її клітинки.

$$C_{0.5} = \begin{pmatrix} 61 & 14 \\ 12 & 205 \end{pmatrix}, \qquad C_{\text{Юден}} = \begin{pmatrix} 69 & 6 \\ 30 & 187 \end{pmatrix}.$$

Рядки — справжні класи 0,1; стовпці — прогноз 0,1. TN=61: доступні правильно визначені; FP=14: доступні помилково названі дорогими; FN=12: дорогі помилково названі доступними; TP=205: дорогі правильно визначені.

(3е–ж) Побудуйте ROC, оберіть поріг Юдена й порівняйте метрики.



$J = Sensitivity + Specificity - 1$, $Sensitivity = TP/(TP+FN)$, $Specificity = TN/(TN+FP)$.

Поріг обрано на окремій вибірці: **c=0.81074853**. Тестова AUC=**0.96184332**. Нижче — обидва пороги на тих самих 292 перевірочних будинках:

Поріг	c	Чутливість	Специфічність	Accuracy
0.5	0.500000	0.944700	0.813333	0.910959
Юден	0.810749	0.861751	0.920000	0.876712

Поріг зріс: модель стала більш консервативною щодо класу 1. FP зменшилися з 14 до 6, FN зросли з 12 до 30. Специфічність зросла, чутливість і точність зменшилися. ROC-AUC від зміни порогу не змінюється.