

Задача 1. Описова статистика та теорія ймовірностей: Реальні дані (ceosal1)

Частина 1. У цій частині ми працюватимемо з інструментами та методами візуалізації даних і обчислення деяких простих характеристичних показників. Наша мета — застосувати всі основні методи описової статистики та зробити правильні висновки. За допомогою вбудованого модуля `get_rdataset("ceosal1" "wooldridge")` бібліотеки `statsmodels` у Python ми завантажимо реальні дані про компенсації виконавчих директорів (CEO) США та деякі додаткові змінні, перелічені нижче:

- **salary** — річна заробітна плата + бонуси CEO у тис. доларів США.
- **pcsalary** — відсоткова зміна заробітної плати порівняно з минулим роком.
- **age** — вік CEO у роках (оскільки оригінальний історичний набір даних ceosal1 Вулдріджа містить виключно корпоративні фінансові показники, моделювання показника age реалізуйте в середовищі Python за допомогою генератора випадкових чисел на основі нормального розподілу $N(53, 6.5^2)$, що повністю відповідає реальним демографічним характеристикам топменеджменту великих корпорацій).
- **sales** — загальний дохід від продажів фірми за рік у млн доларів США.
- **roe** — рентабельність власного капіталу фірми (Return on Equity) у %.

Наша мета — оцінити набір даних за допомогою базових інструментів.

- Для змінної **salary** обчисліть поширені міри центральної тенденції (показники положення): середнє значення, 5%-усічене середнє, медіану, верхній та нижній квартилі, верхній та нижній 5%-квантілі. Дайте економічну інтерпретацію для кожної міри положення (принаймні одне речення для кожного показника).
- Побудуйте емпіричну кумулятивну функцію розподілу (ECDF). Обчисліть та поясніть в економічних термінах такі величини:
 - $\hat{F}^{-1}(0.1)$ та $\hat{F}^{-1}(0.9)$
 - $\hat{F}(1000)$ та $1 - \hat{F}(2500)$
- Побудуйте гістограму для **salary** та діаграму розмаху (Box-plot), використовуючи стандартні налаштування в Python (`matplotlib/seaborn`). Як інтерпретується площа прямокутника на гістограмі? Пов'яжіть елементи діаграми розмаху з обчисленими вище мірами положення.
- Який висновок можна зробити про розподіл даних? Чи залишаються доречними обчислені вище міри положення? Обчисліть та обговоріть відповідну міру симетрії (коефіцієнт асиметрії Фішера-Пірсона).
- Перевірте, який метод використовується у вашому програмному забезпеченні (наприклад, у бібліотеці `seaborn`) для обчислення оптимальної ширини інтервалу (або кількості стовпчиків) у гістограмі. Коротко опишіть його тут. Побудуйте занадто деталізовану ($bins = 150$) та занадто узагальнену ($bins = 3$) гістограми. Чого ми можемо навчитися з цих рисунків?

- (д) Існують методи, які допомагають зробити розподіл вибірових даних більш симетричним. Розгляньте натуральний логарифм заробітної плати: $\ln(\text{salary})$. Побудуйте гістограму (та діаграму розмаху) і порівняйте їх із рисунками для вихідних даних. Обчисліть середнє значення та медіану. Який висновок можна зробити з нових значень? Надайте економічну інтерпретацію.

Частина 2. Тепер проведіть поглиблений аналіз даних (без логарифмування)

- (а) Ми припускаємо, що заробітна плата CEO та інші змінні компанії пов'язані між собою. Обчисліть коефіцієнти кореляції Пірсона та зобразіть їх у вигляді теплової карти (кореляційної карти). Обговоріть силу та напрямки кореляцій.
- (б) Побудуйте діаграми розсіювання (матричний графік `pairplot` у Python). Зробіть висновок, чи доречні тут лінійні коефіцієнти кореляції. Тепер обчисліть кореляції Спірмена та побудуйте для них теплову карту. Порівняйте отримані результати з результатами Пірсона.
- (в) Поясніть своїми словами концептуальну різницю між двома коефіцієнтами кореляції та пов'яжіть її з лінійною і монотонною залежністю.
- (г) Розгляньте дві підвибірки: CEO молодші за 50 років і старші за 50 років. Побудуйте для обох підвибірок накладені одна на одну гістограми / емпіричні функції розподілу (ecdf) та обговоріть результати. Чого ми можемо навчитися з відповідних мір положення та розсіювання?

Частина 3. Розгляньте інше групування даних. Визначте групи на основі рівнів заробітної плати CEO (S) та їхнього віку (A):

$$\begin{cases} S_1 : \text{якщо } \text{salary} < 700 \text{ тис. \$;} \\ S_2 : \text{якщо } \text{salary} \geq 700, \text{ але } < 1300 \text{ тис. \$;} \\ S_3 : \text{якщо } \text{salary} \geq 1300 \text{ тис. \$;} \end{cases} \quad \begin{cases} A_1 : \text{якщо } \text{age} < 55 \text{ років;} \\ A_2 : \text{якщо } \text{age} \geq 55 \text{ років.} \end{cases}$$

- (а) Зведіть дані у таблицю спряженості розміром 2×3 з абсолютними та відносними частотами за допомогою засобів кростабуляції в Python (`pd.crosstab`).
- (б) Дайте економічну та статистичну інтерпретацію значень n_{12} , h_{12} , n_1 та h_1 на основі отриманої таблиці.
- (в) Обчисліть відповідну міру залежності для якісних ознак S_i та A_j (коефіцієнт спряженості Крамера або χ^2 -критерій Пірсона). Який висновок можна зробити з її значення? Що ми можемо сказати про зв'язок між віком керівника та рівнем його заробітної плати?

Задача 2. Описова статистика та теорія ймовірностей: Змодельовані дані

Частина 1. На практиці реальні економічні дані майже завжди є неоднорідними. Щоб відобразити цей ефект, ми “забруднюємо” базовий набір даних, додаючи підвибірку з іншими статистичними характеристиками.

- (а) Згенеруйте базову вибірку обсягом $n_1 = 100$ із нормального розподілу $N(10, 1^2)$. Для отримання реалістичної неоднорідної сукупності додайте до цих даних нову вибірку обсягом m , змодельовану з розподілу $N(20, 2^2)$, тобто $\mu_2 = 20$ та $\sigma_2^2 = 4$ ($\sigma_2 = 2$). Змінюйте обсяг забруднення m від 10 до 200 з кроком 20. Обчисліть сукупне середнє значення, медіану та вибіркиму дисперсію як функції від параметра m . Обговоріть вплив зростання неоднорідності на ці міри положення та розсіювання.
- (б) Побудуйте діаграми розмаху (Box-plots) та гістограми щільності для кожної підвибірки окремо, а також для всієї об'єднаної вибірки для кількох контрастних значень m ($m \in \{20, 100, 200\}$).

Частина 3. Наступним кроком є математичне моделювання двох випадкових величин із наперед заданим теоретичним значенням коефіцієнта лінійної кореляції.

- (а) Нехай $U \sim N(0, 1)$ та $V \sim N(0, 1)$ є незалежними випадковими величинами. Побудуємо нові змінні за правилом лінійного перетворення: $U^* = U$ та $V^* = \rho U + \sqrt{1 - \rho^2}V$. Математично доведіть, що теоретична кореляція $\text{Corr}(U^*, V^*) = \rho$, а дисперсії обох трансформованих змінних $\text{Var}(U^*)$ та $\text{Var}(V^*)$ дорівнюють одиниці.
- (б) Використовуйте цей алгоритм для генерації двох вибірок обсягом $n = 100$ для різних значень параметра ρ (змінюйте ρ від -0.9 до 0.9 із кроком 0.2). Обчисліть вибіркові коефіцієнти кореляції Пірсона (r) та Спірмена (ρ_{sp}). Побудуйте графік залежності отриманих вибіркових коефіцієнтів від початкового параметра ρ для порівняння двох методів.
- (в) Виконайте нелінійне, але строго монотонне перетворення для змінної V^* , взявши експоненту: $V_{exp} = \exp(V^*)$. Перевірте вплив цього нелінійного перетворення на коефіцієнти кореляції Пірсона та Спірмена. Надайте візуалізацію результатів та обґрунтуйте економіко-статистичні висновки.

Задача 3. Описова статистика та теорія ймовірностей: Ймовірності та розподіли

Частина 1. Усі студенти належать до однієї з двох груп: добре підготовлені до іспиту (група A) та не дуже добре підготовлені (група B). “Добре підготовлений” студент складає іспит із ймовірністю 80%, а “не дуже добре підготовлений” — із ймовірністю 30%. Ми припускаємо, що лише 10% усіх студентів належать до групи B .

- A : випадково вибраний студент належить до групи A ;
 - B : випадково вибраний студент належить до групи B ;
 - E : випадково вибраний студент складає іспит.
- (а) Яка ймовірність того, що випадково вибраний студент складе іспит ТА належить до групи A ?

- (b) Яка ймовірність того, що випадково вибраний студент складе іспит?
- (c) Яка ймовірність того, що студент, який склав іспит, належить до групи B ?

Частина 2. Декан та керівник програми запрошують усіх студентів на барбекю-вечірку наприкінці року. Серед гостей є п'ять вегетаріанців. Через брак практики у майстра грилю з приготуванням овочів, порція овочів підгорає вщент із ймовірністю 60%.

- (a) Яка ймовірність того, що жодна з п'яти порцій овочів не підгорить?
- (b) Яка ймовірність того, що рівно дві з п'яти порцій овочів підгорять?
- (c) Яка ймовірність того, що принаймні три з п'яти порцій підгорять?

Частина 3. Нехай X — щотижнева дохідність акції A . Ми припускаємо, що вона підпорядковується нормальному розподілу з $\mu = 0.03$ (3%) та $\sigma^2 = 0.02$. Ми інвестуємо 40% нашого капіталу в 10 таких акцій (порівну), а решту 60% — у безризиковий актив із дохідністю $r_f = 0.01$.

- (a) Обчисліть ймовірність того, що дохідність однієї акції є:
 - i. більшою за 0.01; ii. більшою або рівною 0.01; iii. меншою за 0.01; iv. лежить між 0.01 та 0.03.
- (b) Визначте розподіл дохідності портфеля, вказавши вид розподілу та обчисливши його параметри (припустивши незалежність активів).
- (c) Як кореляція між активами може вплинути на дисперсію інвестицій? Яка формула підтверджує вашу думку?

Частина 4. За допомогою засобів Python завантажте щотижневі ціни та розрахуйте дохідність акцій Tesla Inc. (TSLA) за останні два роки. Обчисліть ймовірність того, що дохідність Tesla впаде: а) нижче -2% ; б) нижче -4% .

- (a) Обчисліть цю ймовірність, використовуючи інструменти описової статистики (емпіричну функцію розподілу).
- (b) Обчисліть цю ймовірність, припускаючи, що дохідність підпорядковується нормальному розподілу з параметрами вибіркового середнього та дисперсії.
- (c) Порівняйте отримані ймовірності. Обговоріть переваги та недоліки обох методів.

Частина 5. Припустимо, що ціна заданого активу може або зменшуватися, або збільшуватися в кожен період часу. Така модель називається біноміальною. Ймовірність руху вгору становить 55%, а початкова ціна $S(0) = 10$. Дохідність при русі вгору та вниз дорівнює 0.02 та -0.01 відповідно. Розгляньте утримання активу протягом кількох періодів.

- (a) Обчисліть ймовірність того, що ціна акції зросте:
 - i. ... п'ять періодів поспіль.
 - ii. ... три періоди поспіль.
 - iii. ... у трьох із п'яти періодів.
 - iv. ... у 10 із 15 періодів.

(b) Обчисліть очікувану дохідність цієї інвестиції після двох періодів.

Частина 6. Обчисліть наступні ймовірності для розподілів $N(0, 1)$, t_2 (розподіл Стьюдента з 2 ступенями свободи), $Exp(1)$ (експоненціальний з $\lambda = 1$), χ_3^2 (Хі-квадрат з 3 ступенями свободи):

(a) $P(1 < X < 1.5)$

(b) $P(1 \leq X < 1.5)$

(c) $P(1 < X)$

(d) $P(X \leq 1.5)$

(e) $P(X = 1.5)$